



SAPIENZA
UNIVERSITÀ DI ROMA

**Facoltà di Ingegneria dell'Informazione, Informatica e
Statistica
Dipartimento di Informatica**

DNA Sequence

Autori:

Simone Lidonnici - (2061343)

Marco Casu - (2041262)

19 gennaio 2025

1 Introduzione

Le parti principali di codice da parallelizzare sono la creazione della sequenza e la ricerca dei pattern. Per sequenze medio-piccole quest'ultima compone la maggior parte del tempo di compilazione, mentre aumentando la grandezza della sequenza (nell'ordine dei miliardi), la maggior parte del tempo è richiesto per generare la sequenza. Da notare che nel programma sequenziale il tempo non conta la generazione di quest'ultima mentre nei programmi paralleli (MPI, OpenMP, CUDA e MPI+OpenMP) si, cosa che causa una diminuzione dello speedup.

1.1 Test e calcolo dello speedup

Le varie versioni del programma sono state testate sul cluster eseguendo 10 test e controllando il tempo medio di essi, scartando dal calcolo della media il caso peggiore ed il caso migliore, in particolare il test è stato eseguito con i seguenti parametri:

500000 0.35 0.2 0.25 30000 2000 1000 30000 2000 1000 500 100 M 4353435


2 MPI

Nel programma MPI la ricerca dei pattern è stata distribuita uniformemente tra i rank, se t è il numero dei processi, allora ognuno ricercherà $\lceil \frac{n}{t} \rceil$ pattern, con n numero totale di pattern (sia sample che random). Se $\frac{n}{t}$ non è un numero intero, l'ultimo rank ricercherà meno pattern rispetto ad ogni altro. Per avere poi il valore corretto dei pattern trovati e dei pattern in ogni punto della sequenza vengono eseguite delle collettive `MPI_Reduce` su `seq_matches` e `pat_found`.

Riguardo la generazione della sequenza, è stato osservato che, questa, risulta più veloce nella versione sequenziale, anche se viene adoperato un singolo thread, la funzione `generate_random_sequence` impiega sempre meno tempo ad essere eseguita nella versione sequenziale piuttosto che in quella parallela. Sono stati tentati due approcci:

- Si è inizialmente provato a far generare l'intera sequenza ad un solo processo, per poi eseguire una `MPI_Broadcast`, condividendola a tutti gli altri processi. Tale versione si è rivelata più veloce della versione iniziale (in cui ogni rank genera autonomamente la sequenza) ma comunque più lenta della versione sequenziale.
- La seconda opzione, presente nel file finale, è stata quella di dividere la sequenza tra i vari rank, nello stesso modo in cui vengono divisi i pattern e poi eseguire una `MPI_Allreduce` per far avere a tutti i rank la sequenza completa. Data la natura puramente sequenziale delle funzioni rng, ogni rank esegue un `rng_skip` per poter iniziare a generare i suoi numeri random da un punto avanzato della sequenza.

Di seguito si può vedere il grafico dei tempi e dello speed up in relazione al numero di processi MPI, i test sono stati eseguiti con il numero massimo di processi su un nodo (32) e aumentando i nodi progressivamente:




L'esecuzione sequenziale (non riportata nel grafico) ha impiegato 71.27 secondi.

Se si vogliono consultare le informazioni in maniera più pratica, si può controllare la seguente tabella:

numero di processi	tempo	speedup	efficienza
sequenziale	71.27	1	1
32	2.71	26.27	0.82
64	1.57	45.07	0.70
96	1.10	64.64	0.67
128	0.83	84.97	0.66
160	0.94	75.03	0.46
192	0.68	103.28	0.53
224	1.06	66.95	0.29
256	1.16	61.32	0.23

Nota : il tempo medio per l'esecuzione con 256 rank risulta maggiore al tempo medio con 96 rank, anche se il caso migliore risulta più rapido, non è chiaro se l'aleatorietà delle differenze di tempo fra differenti esecuzioni del programma sia dovuta al sovraccarico del cluster, sono riportati qui sotto i grafici e la tabella dei tempi di esecuzione nei *casi migliori*:

numero di processi	tempo	speedup	efficienza
sequenziale	71.27	1	1
32	2.29	31.01	0.96
64	1.19	59.71	0.93
96	0.82	86.91	0.90
128	0.78	91.37	0.71
160	0.63	113.13	0.70
192	0.52	137.06	0.71
224	0.50	142.54	0.63
256	0.44	161.98	0.63



Si noti come nel caso migliore, all'aumentare dei thread il tempo va sempre diminuendo.


3 OpenMP

Nel programma OpenMP per quanto riguarda la ricerca dei pattern abbiamo creato delle variabili `pat_matches` e `seq_matches` private per ogni thread e abbiamo parallelizzato solamente il ciclo più esterno, tramite un `#pragma omp for`, questo perché i tre cicli non potevano essere collassati in uno unico data la presenza di `break` al loro interno.

Dopo il ciclo `for` relativo alla ricerca dei pattern ogni thread avrà operato sulle proprie copie private di `pat_matches` e `seq_matches`. Sarà necessario collassare i risultati parziali ottenuti da ogni thread, sommandone i valori. A tal proposito, sarà necessario sequenziare una porzione di codice con la direttiva `#pragma omp critical`, in cui ogni thread sommerà i valori di `pat_matches` e `seq_matches` per avere i valori finali corretti.

Per quanto riguarda invece la creazione della sequenza abbiamo usato lo stesso approccio di MPI, cioè dividerla in parti uguali in base all'id del thread e far eseguire ad ogni thread `rng_skip` fino al punto dove deve iniziare a generare i propri numeri random. Per impostare il numero di thread è stato aggiunto un argomento in input, in modo da poterli impostare da linea di comando.

Di seguito si può vedere il grafico dei tempi e dello speedup in relazione al numero di thread, i test sono stati eseguiti aumentando il numero di thread progressivamente:



Si osservi come la decrescita del tempo impiegato a terminare il programma è inizialmente esponenziale. In seguito, è riportata la tabella dei tempi e dello speed up:

numero di thread	tempo	speedup	efficienza
sequenziale	71.27	1	1
2	36.94	1.92	0.96
4	18.62	3.82	0.95
8	9.48	7.51	0.93
16	4.84	14.71	0.91
32	2.93	24.24	0.75

Si noti come a parità di processi (nel caso con 32 thread), l'esecuzione parallela in MPI risulta più efficiente rispetto quella in OpenMP.